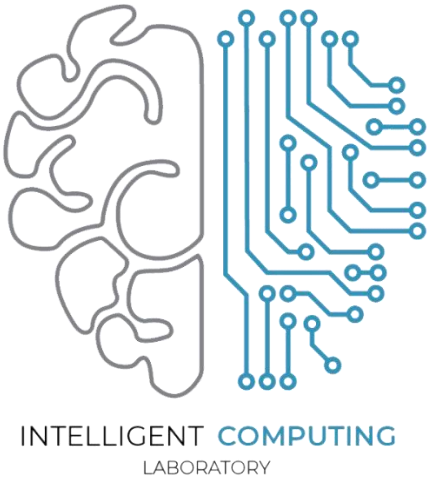
LAPORAN TEORI

STRUKTUR DATA



NAMA : Iskandar Zulkarnain Wijaya

NIM : 202331121

KELAS : C

DOSEN : Dr. Efy Yosrita, S.Si., M.Kom.

NO.PC : 3

ASISTEN : Muhammad Raka Ilham

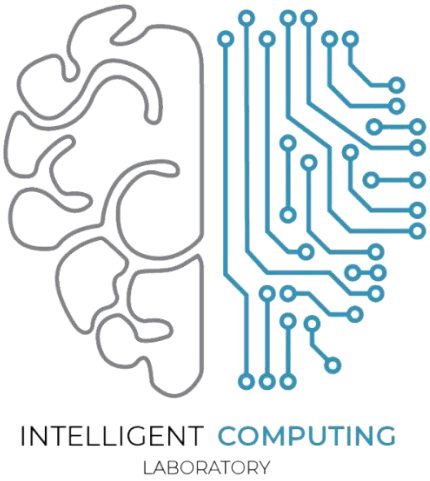
INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2025/2026

LAPORAN PRAKTIKUM

STRUKTUR DATA



NAMA : Iskandar Zulkarnain Wijaya

NIM : 202331121

KELAS : C

DOSEN : Dr. Efy Yosrita, S.Si., M.Kom.

NO.PC : 3

ASISTEN : Muhammad Raka Ilham

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2025/2026

1. EDA

```
[1]: # Iskandar Zulkarnain Wijaya_202331121
import matplotlib.pyplot as plt
import pandas as pd
```

```
[2]: # Iskandar Zulkarnain Wijaya_202331121
df = pd.read_csv("Expanded_Dataset.csv")
print(df.head())
```

```
   Year Quarter  Product Model 5G Capability  Units Sold   Revenue ($)  \
0  2019      Q1     Galaxy S10            No       26396  4.212951e+06
1  2019      Q1  Galaxy Note10            No       25671  7.240266e+06
2  2019      Q1     Galaxy S20            No       16573  2.560833e+07
3  2019      Q1  Galaxy Note20            No        7177  2.198442e+07
4  2019      Q1     Galaxy S21            No       45633  1.634244e+07

   Market Share (%)  Regional 5G Coverage (%)  5G Subscribers (millions)  \
0              1.04                     57.36                      39.55
1              2.82                     85.80                      42.58
2             -0.03                     47.02                       3.78
3              0.84                     25.70                      23.41
4              2.36                     89.13                      44.43

   Avg 5G Speed (Mbps)  Preference for 5G (%)              Region
0               293.10                  55.87        Asia-Pacific
1                67.46                  37.26       Latin America
2                77.25                  84.66  Middle East & Africa
3               105.27                  40.03       North America
4               206.17                  76.88       Latin America
```

```
[3]: # Iskandar Zulkarnain Wijaya_202331121
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 12 columns):
 #   Column                     Non-Null Count  Dtype
---  ------                     --------------  -----
 0   Year                       1000 non-null   int64
 1   Quarter                    1000 non-null   object
 2   Product Model              1000 non-null   object
 3   5G Capability              1000 non-null   object
 4   Units Sold                 1000 non-null   int64
 5   Revenue ($)                1000 non-null   float64
 6   Market Share (%)           1000 non-null   float64
 7   Regional 5G Coverage (%)   1000 non-null   float64
 8   5G Subscribers (millions)  1000 non-null   float64
 9   Avg 5G Speed (Mbps)        1000 non-null   float64
 10  Preference for 5G (%)      1000 non-null   float64
 11  Region                     1000 non-null   object
dtypes: float64(6), int64(2), object(4)
memory usage: 93.9+ KB
```

Untuk cell 1 melakukan import library utama yang dibutuhkan pada analisis data,seperti pandas digunakan untuk memanipulasi dan mengelola dalam bentuk tabel,sedangkan matplotlib.pyplot digunakan untuk membuat visualisasi grafik dari data.
Cell 2 pada perintah read_csv berfungsi untuk membaca file dataset dengan format CSV dan disimpin di dalam variable df. Fungsi df.head() diguankan untuk menampilkan 5 baris pertama dari dataset untuk memastikan data telah berhasil.
Pada cell 3 fungsi info() untuk melihat seluruh dataset,termasuk jumlah total baris,kolom,nama masing2 kolom,tipe data setiap kolom,dan jumlah memori yang digunakan oleh DataFrame tersebut.

```
[4]: # Iskandar Zulkarnain Wijaya_202331121
print(df.describe())
```

```
              Year    Units Sold   Revenue ($)  Market Share (%)  \
count  1000.000000   1000.000000  1.000000e+03       1000.000000
mean   2021.456000  32842.990000  3.019733e+07          3.723570
std       1.700281  16039.770572  1.837941e+07          1.991108
min    2019.000000   5309.000000  2.987436e+06         -0.490000
25%    2020.000000  19327.250000  1.460749e+07          2.635000
50%    2021.000000  33689.000000  2.801200e+07          3.760000
75%    2023.000000  43911.000000  4.180391e+07          5.282500
max    2024.000000  64883.000000  8.426494e+07          6.950000

       Regional 5G Coverage (%)  5G Subscribers (millions)  \
count               1000.000000                1000.000000
mean                  66.889720                  30.152080
std                   19.254095                  14.537781
min                   25.340000                  -0.890000
25%                   50.400000                  18.412500
50%                   67.050000                  29.915000
75%                   83.210000                  44.360000
max                  103.920000                  54.940000

       Avg 5G Speed (Mbps)  Preference for 5G (%)
count          1000.000000            1000.00000
mean            179.225560              67.14291
std              70.470934              15.75925
min              50.370000              37.14000
25%             120.410000              53.26750
50%             177.390000              66.96000
75%             238.860000              80.99000
max             298.700000              94.84000
```

```
[5]: # Iskandar Zulkarnain Wijaya_202331121
print(df.isna().sum())
```

```
Year                         0
Quarter                      0
Product Model                0
5G Capability                0
Units Sold                   0
Revenue ($)                  0
Market Share (%)             0
Regional 5G Coverage (%)     0
5G Subscribers (millions)    0
Avg 5G Speed (Mbps)          0
Preference for 5G (%)        0
Region                       0
dtype: int64
```

Fungsi dari cell 4 yaitu describe() untuk menghasilkan ringkasan statistik deskriptif untuk kolom numerik,seperti mean,std,nilai minimum,kuartil (25%,50%,75%) dan nilai maksimum.
Lalu di cell ke 5 ada peintah isna().sum() buat mendeteksi jumlah missing valuenya pada setiap kolom.bisa dilihat kolom nilainya 0 yang berarti dataset ini bersih dan tidak kosong

```
[6]: # Iskandar Zulkarnain Wijaya_202331121
print("Quarter:", df["Quarter"].unique())
print("Product Model:", df["Product Model"].unique())
print("5G Capability:", df["5G Capability"].unique())
print("Region:", df["Region"].unique())

Quarter: ['Q1' 'Q2' 'Q3' 'Q4']
Product Model: ['Galaxy S10' 'Galaxy Note10' 'Galaxy S20' 'Galaxy Note20' 'Galaxy S21'
 'Galaxy A32 5G' 'Galaxy A52 5G' 'Galaxy A73 5G' 'Galaxy Z Fold2 5G'
 'Galaxy Z Flip3 5G' 'Galaxy S22 5G' 'Galaxy Z Fold3 5G' 'Galaxy A14 5G'
 'Galaxy S23 5G' 'Galaxy Z Flip5 5G']
5G Capability: ['No' 'Yes']
Region: ['Asia-Pacific' 'Latin America' 'Middle East & Africa' 'North America'
 'Europe']

[7]: # Iskandar Zulkarnain Wijaya_202331121
# Mengisi kolom numerik dengan mean, dan kolom kategorik dengan modus
for col in df.select_dtypes(include=["float64", "int64"]).columns:
  df[col] = df[col].fillna(df[col].mean())

for col in df.select_dtypes(include=["object"]).columns:
  df[col] = df[col].fillna(df[col].mode()[0])

print("Data kosong setelah diisi:")
print(df.isna().sum().sum())

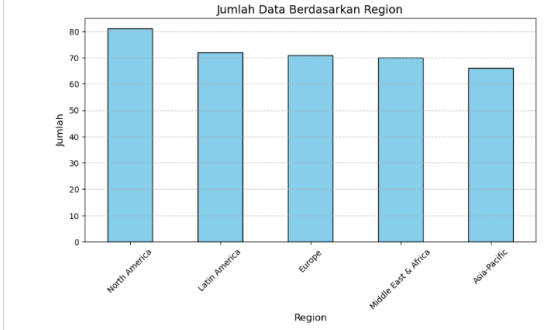
Data kosong setelah diisi:
0

[8]: # Iskandar Zulkarnain Wijaya_202331121
print("Jumlah data duplikat awal:", df.duplicated().sum())
df = df.drop_duplicates()
df.info()

Jumlah data duplikat awal: 640
<class 'pandas.core.frame.DataFrame'>
Index: 360 entries, 0 to 359
Data columns (total 12 columns):
 #   Column                     Non-Null Count  Dtype
---  ------                     --------------  -----
 0   Year                       360 non-null    int64
 1   Quarter                    360 non-null    object
 2   Product Model              360 non-null    object
 3   5G Capability              360 non-null    object
 4   Units Sold                 360 non-null    int64
 5   Revenue ($)                360 non-null    float64
 6   Market Share (%)           360 non-null    float64
 7   Regional 5G Coverage (%)   360 non-null    float64
 8   5G Subscribers (millions)  360 non-null    float64
 9   Avg 5G Speed (Mbps)        360 non-null    float64
 10  Preference for 5G (%)      360 non-null    float64
 11  Region                     360 non-null    object
dtypes: float64(6), int64(2), object(4)
memory usage: 36.6+ KB
```

Cell 6 puya fungsi unique() yang digunakan untuk melihat kategori atau nilai unik yang ada di dalam kolom2 bertipe teks/kategorik seperti Quarter,Product Model,5G,Capability,dan Region,ini berguna untuk mendeteksi apakah ada kesalahan penulisan pada kategori datanya.
Cell 7 ini memastikan bahwa jika terdapat data kosong,kolom angka akan diisi menggunakan nilai mean dan kolom teks/kategorik diisi menggunakan nilai terbanyak(modus).hasil pengisian disimpan kembali dalam dataframe supaya perubahan bersifat permanent.
Cell 8 cuplicate().sum() menghitung apakah ada baris data yang persis sama ganda.dan karena hasilnya 0,tidak ada baris yang dihapus oleh drop.duplicated().

```
[9]: # Iskandar Zulkarnain Wijaya_202331121
plt.figure(figsize=(10, 5))
df["Region"].value_counts().plot(kind="bar", color="skyblue", edgecolor="black")
plt.title("Jumlah Data Berdasarkan Region", fontsize=14)
plt.xlabel("Region", fontsize=12)
plt.ylabel("Jumlah", fontsize=12)
plt.xticks(rotation=45)
plt.grid(axis="y", linestyle="--", alpha=0.7)
plt.show()
```



Dan cell 9 adalah visualisasi Grafik batangnya,

2. WebScrapping

[1]:
```
# Iskandar Zulkarnain Wijaya_202331121
import csv
from bs4 import BeautifulSoup
import requests
```

[2]:
```
# Iskandar Zulkarnain Wijaya_202331121
url = "https://id.tradingeconomics.com/country-list/corruption-rank"
headers = {
    "User-Agent": (
        "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML,"
        " like Gecko) Chrome/120.0.0.0 Safari/537.36"
    )
}

response = requests.get(url, headers=headers)
print("Status Code:", response.status_code)
```

```
Status Code: 200
```

[3]:
```
# Iskandar Zulkarnain Wijaya_202331121
soup = BeautifulSoup(response.text, "html.parser")
table = soup.find("table", class_="table")
rows = table.find_all("tr") if table else []

print(f"Jumlah baris data ditemukan pada tabel: {len(rows)}")
```

```
Jumlah baris data ditemukan pada tabel: 181
```

[4]:
```
# Iskandar Zulkarnain Wijaya_202331121
result = []

for row in rows[1:]:
  cols = row.find_all("td")
  if len(cols) >= 4:
    negara = cols[0].get_text(strip=True)
    terakhir = cols[1].get_text(strip=True)
    sebelum_ini = cols[2].get_text(strip=True)
    referensi = cols[3].get_text(strip=True)

    result.append({
        "negara": negara,
        "terakhir": terakhir,
        "sebelum_ini": sebelum_ini,
        "referensi": referensi,
    })

print("Contoh 3 data teratas:", result[:3])
```

```
Contoh 3 data teratas: [{'negara': 'Denmark', 'terakhir': '1', 'sebelum_ini': '1', 'referensi': '2025-12'}, {'negara': 'Finlandia', 'terakhir': '2', 'sebelum_ini': '2', 'referensi': '2025-12'}, {'negara': 'Singapura', 'terakhir': '3', 'sebelum_ini': '3', 'referensi': '2025-12'}]
```

[5]:
```
# Iskandar Zulkarnain Wijaya_202331121
filename = "corruption_rank.csv"
with open(filename, "w", newline="", encoding="utf-8") as csvfile:
  fieldnames = ["negara", "terakhir", "sebelum_ini", "referensi"]
  writer = csv.DictWriter(csvfile, fieldnames=fieldnames)

  writer.writeheader()
  for item in result:
    writer.writerow(item)

print(f"Data berhasil disimpan ke file {filename}")
```

```
Data berhasil disimpan ke file corruption_rank.csv
```

[6]:
```
# Iskandar Zulkarnain Wijaya_202331121
import pandas as pd
db = pd.read_csv("corruption_rank.csv")
```

[7]:
```
db
```

[7]:

	negara	terakhir	sebelum_ini	referensi
0	Denmark	1	1	2025-12
1	Finlandia	2	2	2025-12
2	Singapura	3	3	2025-12
3	Selandia Baru	4	4	2025-12
4	Norwegia	4	5	2025-12
...	...	...	...	...
175	Libya	177	173	2025-12
176	Yaman	177	173	2025-12
177	Venezuela	180	178	2025-12
178	Somalia	181	179	2025-12
179	Sudan Selatan	181	180	2025-12

180 rows × 4 columns

Proses web scraping data peringkat korupsi dari situs Trading Economics dimulai dengan mengimpor pustaka utama seperti requests untuk mengirim permintaan HTTP ke server, BeautifulSoup untuk mengurai kode HTML, dan csv untuk memproses penyimpanan file. Pada tahap selanjutnya, program melakukan permintaan data ke URL target menggunakan parameter headers (User-Agent) agar akses disetujui oleh server dan menghindari pemblokiran, di mana status code 200 menandakan bahwa halaman berhasil dimuat. Setelah itu, kode HTML diurai menggunakan BeautifulSoup untuk mencari elemen tabel utama yang memuat data dari total 182 negara atau teritori. Program kemudian melakukan perulangan pada setiap baris tabel untuk mengekstrak kolom-kolom penting, yaitu nama negara, nilai peringkat terbaru (terakhir), nilai periode sebelumnya (sebelum_ini), dan tanggal referensi, lalu menyimpannya ke dalam struktur data list. Data yang telah terkumpul kemudian ditulis secara rapi ke dalam file fisik berformat CSV bernama corruption_rank.csv menggunakan modul csv.DictWriter.

3. Regresi Linear

[8]:
```
# Iskandar Zulkarnain Wijaya_202331121
import matplotlib.pyplot as plt
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.model_selection import train_test_split
```

[9]:
```
# Iskandar Zulkarnain Wijaya_202331121
df = pd.read_csv("corruption_rank.csv")
print("Informasi Dataset:")
print(df.info())
print("\nCuplikan Data:")
print(df.head())
```

```
Informasi Dataset:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 180 entries, 0 to 179
Data columns (total 4 columns):
 #   Column       Non-Null Count  Dtype 
---  ------       --------------  ----- 
 0   negara       180 non-null    object
 1   terakhir     180 non-null    int64 
 2   sebelum_ini  180 non-null    int64 
 3   referensi    180 non-null    object
dtypes: int64(2), object(2)
memory usage: 5.8+ KB
None

Cuplikan Data:
          negara  terakhir  sebelum_ini referensi
0        Denmark         1            1   2025-12
1      Finlandia         2            2   2025-12
2      Singapura         3            3   2025-12
3  Selandia Baru         4            4   2025-12
4       Norwegia         4            5   2025-12
```

[10]:
```
# Iskandar Zulkarnain Wijaya_202331121
df["terakhir"] = pd.to_numeric(df["terakhir"], errors="coerce")
df["sebelum_ini"] = pd.to_numeric(df["sebelum_ini"], errors="coerce")
df_clean = df.dropna(subset=["terakhir", "sebelum_ini"])
print(f"Jumlah data setelah dibersihkan: {len(df_clean)} baris")
```

```
Jumlah data setelah dibersihkan: 180 baris
```

[11]:
```
# Iskandar Zulkarnain Wijaya_202331121
X = df_clean[["sebelum_ini"]]
y = df_clean["terakhir"]

print("Fitur (X) shape:", X.shape)
print("Target (y) shape:", y.shape)
```

```
Fitur (X) shape: (180, 1)
Target (y) shape: (180,)
```

[12]:
```
# Iskandar Zulkarnain Wijaya_202331121
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

print(f"Jumlah data latih: {len(X_train)} baris")
print(f"Jumlah data uji: {len(X_test)} baris")
```

```
Jumlah data latih: 144 baris
Jumlah data uji: 36 baris
```

*[13]:
```
# Iskandar Zulkarnain Wijaya_202331121
model = LinearRegression()
model.fit(X_train, y_train)
print("Koefisien (Slope):", model.coef_[0])
print("Intercept:", model.intercept_)
```

```
Koefisien (Slope): 1.0079956956885434
Intercept: 0.2578327590981502
```

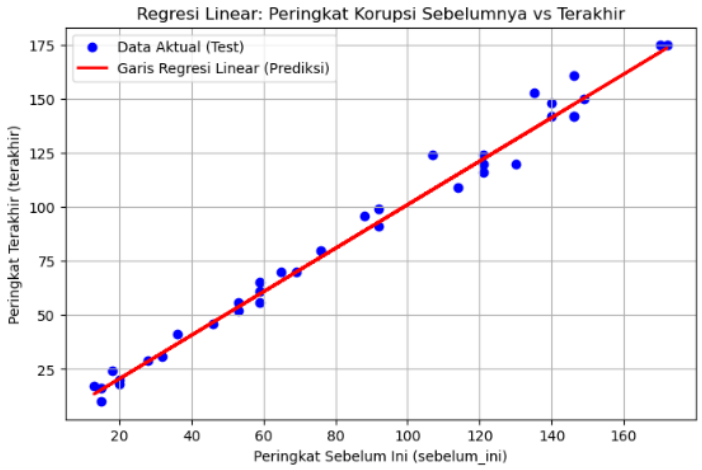
[14]:
```
# Iskandar Zulkarnain Wijaya_202331121
y_pred = model.predict(X_test)

mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f"Mean Squared Error (MSE): {mse:.4f}")
print(f"R-squared Score (R2): {r2:.4f}")
```

```
Mean Squared Error (MSE): 36.5268
R-squared Score (R2): 0.9858
```

[15]:
```
# Iskandar Zulkarnain Wijaya_202331121
plt.figure(figsize=(8, 5))
plt.scatter(X_test, y_test, color="blue", label="Data Aktual (Test)")
plt.plot(
    X_test,
    y_pred,
    color="red",
    linewidth=2,
    label="Garis Regresi Linear (Prediksi)",
)
plt.title("Regresi Linear: Peringkat Korupsi Sebelumnya vs Terakhir")
plt.xlabel("Peringkat Sebelum Ini (sebelum_ini)")
plt.ylabel("Peringkat Terakhir (terakhir)")
plt.legend()
plt.grid(True)
plt.show()
```



Proses analisis menggunakan Regresi Linear dimulai dengan mengimpor berbagai pustaka penting seperti pandas dan numpy untuk pengolahan data, matplotlib.pyplot untuk visualisasi grafik, serta modul dari scikit-learn yang mencakup algoritma LinearRegression, fungsi pemisahan data train_test_split, dan metrik evaluasi seperti mean_squared_error serta r2_score. Pada tahap pemuatan dataset, program membaca file corruption_rank.csv ke dalam struktur DataFrame Pandas untuk memeriksa informasi dasar dan cuplikan baris datanya. Selanjutnya, dilakukan proses pembersihan data (data cleaning) di mana kolom numerik seperti terakhir dan sebelum_ini dikonversi ke format angka dengan aman serta disaring untuk membuang baris yang memiliki nilai kosong (missing values).Setelah data siap, program menetapkan kolom fitur independen X berdasarkan peringkat periode

sebelumnya (sebelum_ini) dan variabel target dependen y berdasarkan peringkat terbaru (terakhir). Data tersebut kemudian dibagi menjadi bagian data latih (training set) dan data uji (testing set) menggunakan fungsi pemisahan data. Model Regresi Linear kemudian diinisialisasi dan dilatih (fit) menggunakan data latih untuk mempelajari pola hubungan linier serta menentukan nilai koefisien dan intercept-nya. Setelah model terlatih, program melakukan pengujian prediksi pada data uji dan menghitung tingkat kesalahan serta akurasinya menggunakan metrik MSE dan skor R^2. Sebagai langkah penutup, hasil analisis divisualisasikan ke dalam bentuk diagram tebar (scatter plot) yang memetakan data aktual dengan garis merah regresi linier, sehingga tren hubungan antar peringkat korupsi dapat dievaluasi dengan jelas.

4. **Decision Tree**

[16]:
```
from sklearn.tree import DecisionTreeRegressor, plot_tree
```

[17]:
```
# Iskandar Zulkarnain Wijaya_202331121
df = pd.read_csv("corruption_rank.csv")
print("Informasi Dataset:")
print(df.info())
```

```
Informasi Dataset:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 180 entries, 0 to 179
Data columns (total 4 columns):
 #   Column       Non-Null Count  Dtype 
---  ------       --------------  ----- 
 0   negara       180 non-null    object
 1   terakhir     180 non-null    int64 
 2   sebelum_ini  180 non-null    int64 
 3   referensi    180 non-null    object
dtypes: int64(2), object(2)
memory usage: 5.8+ KB
None
```

[18]:
```
# Iskandar Zulkarnain Wijaya_202331121
# Membersihkan dan memastikan kolom numerik bersih dari nilai non-angka
df["terakhir"] = pd.to_numeric(df["terakhir"], errors="coerce")
df["sebelum_ini"] = pd.to_numeric(df["sebelum_ini"], errors="coerce")

# Menghapus baris dengan nilai kosong (NaN)
df_clean = df.dropna(subset=["terakhir", "sebelum_ini"])

print(f"Jumlah data siap pakai: {len(df_clean)} baris")
```

```
Jumlah data siap pakai: 180 baris
```

[19]:
```
# Iskandar Zulkarnain Wijaya_202331121
X = df_clean[["sebelum_ini"]]
y = df_clean["terakhir"]

print("Fitur (X) shape:", X.shape)
print("Target (y) shape:", y.shape)
```

```
Fitur (X) shape: (180, 1)
Target (y) shape: (180,)
```

[20]:
```
# Iskandar Zulkarnain Wijaya_202331121
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

print(f"Data Latih: {len(X_train)} baris")
print(f"Data Uji: {len(X_test)} baris")
```

```
Data Latih: 144 baris
Data Uji: 36 baris
```

```
[21]: # Iskandar Zulkarnain Wijaya_202331121
# Mengatur max_depth agar pohon keputusan tidak terlalu kompleks (ove
tree_model = DecisionTreeRegressor(max_depth=4, random_state=42)
tree_model.fit(X_train, y_train)

print("Model Decision Tree berhasil dilatih!")
```

```
Model Decision Tree berhasil dilatih!
```

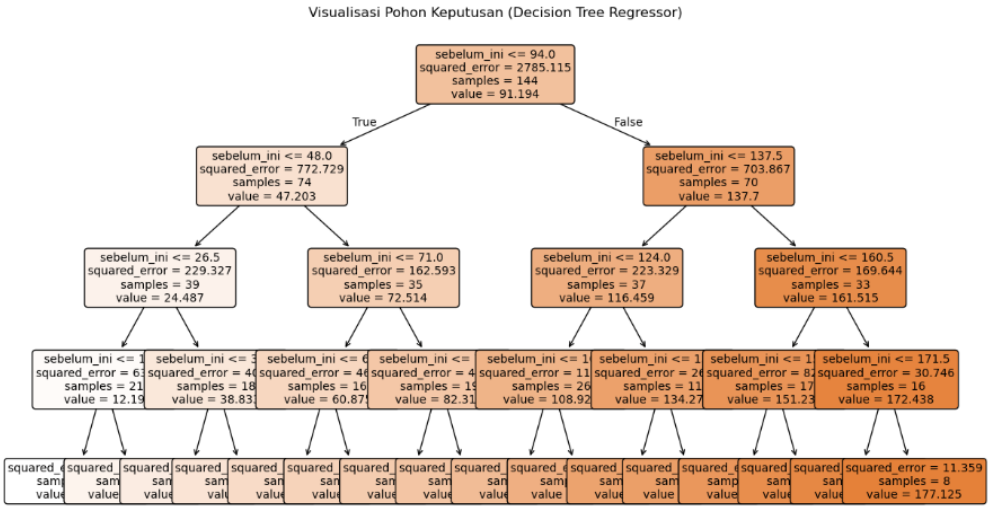
```
[22]: # Iskandar Zulkarnain Wijaya_202331121
y_pred = tree_model.predict(X_test)

mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f"Mean Squared Error (MSE): {mse:.4f}")
print(f"R-squared Score (R2): {r2:.4f}")
```

```
Mean Squared Error (MSE): 49.1994
R-squared Score (R2): 0.9809
```

```
[23]: # Iskandar Zulkarnain Wijaya_202331121
plt.figure(figsize=(14, 8))
plot_tree(
    tree_model,
    feature_names=["sebelum_ini"],
    filled=True,
    rounded=True,
    fontsize=10,
)
plt.title("Visualisasi Pohon Keputusan (Decision Tree Regressor)")
plt.show()
```



Proses pemodelan menggunakan Decision Tree dimulai dengan mengimpor pustaka pendukung dari scikit-learn, yaitu DecisionTreeRegressor untuk regresi berbasis pohon dan plot_tree untuk visualisasi struktur pohon, serta modul metrik evaluasi seperti mean_squared_error dan r2_score. Pada tahap awal, dataset corruption_rank.csv dimuat dan dibersihkan dari nilai kosong (missing values) pada kolom fitur sebelum_ini dan target terakhir. Selanjutnya, variabel independen X dan dependen y ditentukan sebelum data dibagi menjadi data latih (training set) dan data uji (testing set) menggunakan rasio 80:20. Model Decision Tree Regressor diinisialisasi dengan parameter kedalaman maksimum (max_depth=4) untuk menjaga performa generalisasi model dan mencegah terjadinya overfitting, lalu dilatih menggunakan data latih. Setelah model mempelajari aturan pemecahan data (splitting rules), pengujian dilakukan terhadap data uji untuk menghitung tingkat kesalahan melalui MSE dan koefisien determinasi R^2. Sebagai penutup, struktur hierarki pohon keputusan divisualisasikan menggunakan fungsi plot_tree ke dalam diagram berbentuk cabang pohon yang memperlihatkan bagaimana kondisi keputusan dibuat berdasarkan nilai fitur peringkat sebelumnya

5. Naive Bayes

```
[1]: # Iskandar Zulkarnain Wijaya_202331121
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeRegressor
```

```
[2]: # Iskandar Zulkarnain Wijaya_202331121
df = pd.read_csv("student_sleep_patterns.csv")
print("Ukuran Dataset (Baris, Kolom):", df.shape)
```

```
Ukuran Dataset (Baris, Kolom): (500, 14)
```

```
[3]: # Iskandar Zulkarnain Wijaya_202331121
df_clean = df.dropna()
print(f"Jumlah baris setelah dibersihkan: {len(df_clean)}")
```

```
Jumlah baris setelah dibersihkan: 500
```

```
[4]: # Iskandar Zulkarnain Wijaya_202331121
X = df_clean[["Study_Hours"]]  # Independent Variable
y = df_clean["Sleep_Duration"]  # Dependent Variable / Target
```

```
[5]: # Iskandar Zulkarnain Wijaya_202331121
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
print("Data Train:", len(X_train), "| Data Test:", len(X_test))
```

```
Data Train: 400 | Data Test: 100
```

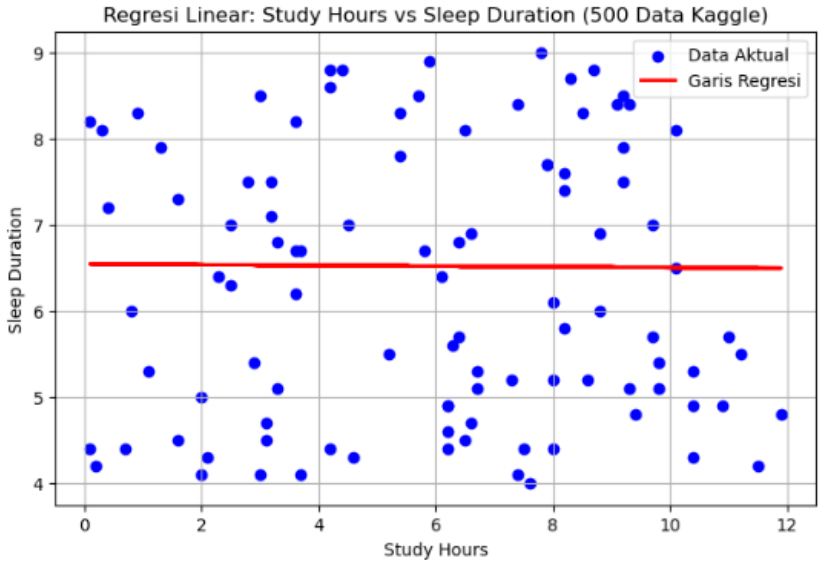
```
[6]: # Iskandar Zulkarnain Wijaya_202331121
model = LinearRegression()
model.fit(X_train, y_train)
print("Slope (Koefisien):", model.coef_[0])
print("Intercept:", model.intercept_)
```

```
Slope (Koefisien): -0.004068945302304803
Intercept: 6.548887223669364
```

```
[7]: # Iskandar Zulkarnain Wijaya_202331121
y_pred = model.predict(X_test)
print("MSE:", mean_squared_error(y_test, y_pred))
print("R2 Score:", r2_score(y_test, y_pred))
```

```
MSE: 2.475693365630744
R2 Score: -0.027982084334346347
```

```
[8]: # Iskandar Zulkarnain Wijaya_202331121
plt.figure(figsize=(8, 5))
plt.scatter(X_test, y_test, color="blue", label="Data Aktual")
plt.plot(X_test, y_pred, color="red", linewidth=2, label="Garis Regresi")
plt.xlabel("Study Hours")
plt.ylabel("Sleep Duration")
plt.title("Regresi Linear: Study Hours vs Sleep Duration (500 Data Kaggle)")
plt.legend()
plt.grid(True)
plt.show()
```



Dataset dengan ukuran tepat 500 baris sangat ideal digunakan untuk latihan pemodelan seperti Regresi Linear dan Decision Tree karena ukurannya yang pas—tidak terlalu kecil

sehingga pola datanya terlihat, namun juga tidak terlalu besar sehingga proses latihannya cepat. Langkah awalnya dimulai dengan memuat file CSV menggunakan Pandas, dilanjutkan dengan tahap pembersihan data (preprocessing) untuk memastikan tidak ada nilai kosong yang mengganggu proses komputasi. Setelah itu, kolom fitur dan target ditentukan, lalu data dibagi menjadi data latih dan data uji dengan rasio standar 80:20. Model kemudian dilatih menggunakan pustaka scikit-learn untuk mencari pola hubungan antarvariabel, di mana hasil akhirnya dievaluasi menggunakan metrik akurasi seperti Mean Squared Error (MSE) dan R^2 Score serta divisualisasikan dalam bentuk grafik agar mudah dianalisis.